

Задачи на проверку гипотез

Введение в DS на УБ и МИРА

1 Задачи с вариантами ответа (кандидаты в квиз)

1. При проверке гипотезы о равенстве средних p -value оказалось равно 0.04. Выберите верный вариант.
 - (a) Основная гипотеза не отвергается на любом разумном уровне значимости.
 - (b) Основная гипотеза не отвергается на уровне значимости 1%.
 - (c) Основная гипотеза не отвергается на уровне значимости 5%.
 - (d) Основная гипотеза не отвергается на уровне значимости 10%.
2. Проверяется гипотеза о равенстве средних против двусторонней альтернативы. Пусть при верной H_0 $Z \sim \mathcal{N}(0, 1)$. Чему примерно равно соответствующее p -value, если
 - (a) $Z_{obs} = -15$?
 - (b) $Z_{obs} = 0$?
 - (c) $Z_{obs} = 1.96$?
 - (d) $Z_{obs} = 7$?
3. Пусть X_1, \dots, X_N – выборка независимых одинаково распределённых нормальных величин, $X_i \sim \mathcal{N}(\mu, \sigma^2)$. Предположим, что $N = 1000$. Проверяется гипотеза $\mu = 2$ против двусторонней альтернативы. На выбор есть всего два теста: Z -тест и t -тест. Выберите все верные варианты.
 - (a) Тестовая статистика может иметь распределение t_{1000} .
 - (b) Тестовая статистика может иметь распределение t_{500} .
 - (c) Тестовая статистика может иметь распределение, очень похожее на $\mathcal{N}(0, 1)$.
 - (d) Тестовая статистика может иметь распределение, очень похожее на $\mathcal{N}(1000, 2)$.
4. Определите тип ошибки (I или II рода) по описанию ситуации.
 - (a) Мобильный робот врезался в стену. Нулевая гипотеза: впереди нет препятствия.
 - (b) Сканер отпечатка пальца не дал согласие на разблокировку системы для зарегистрированного пользователя. Нулевая гипотеза: пользователь есть в базе.
5. Будет ли отвергнута гипотеза о независимости при использовании χ^2 -критерия согласия Пирсона на уровне значимости 5%, если

- (a) $\chi^2_{obs} = 1$?
- (b) $\chi^2_{obs} = 50$?
- (c) $\chi^2_{obs} = 100$?

В каждом случае нарисуйте картинку.

2 Задачи с открытым ответом (для тренировки техники проверки гипотез)

1. Рассмотрим выборку независимых одинаково распределённых нормальных случайных величин

$$X = [3, 12, 4, 18, 9, 2, 15],$$

$$X_i \sim \mathcal{N}(\mu, \sigma^2).$$

- (a) Проверьте гипотезу

$$\begin{cases} H_0 : \mu = 3, \\ H_1 : \mu \neq 3 \end{cases}$$

на уровне значимости 5%.

- (b) Постройте 90%-ый доверительный интервал для μ .

2. Рассмотрим выборку независимых одинаково распределённых нормальных случайных величин

$$X = [3, 12, 4, 18, 9, 2, 15],$$

$$X_i \sim \mathcal{N}(\mu, 9).$$

- (a) Проверьте гипотезу

$$\begin{cases} H_0 : \mu = 3, \\ H_1 : \mu \neq 3 \end{cases}$$

на уровне значимости 10%.

- (b) Постройте 95%-ый доверительный интервал для μ .

3. Рассмотрим выборку независимых одинаково распределённых случайных величин X_1, \dots, X_{200} , где $X_i \sim \mathcal{N}(\mu, \sigma^2)$. Оказалось, что

$$\sum_{i=1}^{200} X_i = 20, \quad \sum_{i=1}^{200} X_i^2 = 500.$$

- (a) Найдите \bar{X} и $\hat{\sigma}^2$.

- (b) Проверьте гипотезу

$$\begin{cases} H_0 : \mu = 2, \\ H_1 : \mu \neq 2 \end{cases}$$

на уровне значимости 1%.

- (c) Постройте 95%-ый доверительный интервал для μ и при помощи него проверьте гипотезу из предыдущего пункта (уже на новом уровне значимости).

(d) **(пункт со звёздочкой)** Запишите интеграл, при помощи которого можно рассчитать p -value для полученной статистики. Посчитайте этот интеграл при помощи Wolfram Alpha. Убедитесь, что результаты проверки совпадают с предыдущими двумя пунктами.

4. **(хитрая задача)** Рассмотрим выборку независимых одинаково распределённых случайных величин X_1, \dots, X_{10} . Известно, что распределение X_i не является нормальным. Проверьте гипотезу $H_0 : \mathbb{E}(X_i) = 3$ против двусторонней альтернативы на уровне значимости 5%.

5. **(хитрая задача)** Рассмотрим выборку независимых одинаково распределённых случайных величин Бернулли

$$X = [0, 1, 1, 0, 1, 0, 1],$$

$$X_i \sim \text{Bern}(p).$$

Проверьте гипотезу $H_0 : p = 0.3$ против двусторонней альтернативы на уровне значимости 5%.

6. Рассмотрим выборку независимых одинаково распределённых бернулевских случайных величин X_1, \dots, X_{500} , где $X_i \sim \text{Bern}(p)$. Оказалось, что в этой выборке ровно 300 единиц и 200 нулей.

(a) Найдите \hat{p} и оценку дисперсии X_i .

(b) Проверьте гипотезу

$$\begin{cases} H_0 : p = 0.5, \\ H_1 : p \neq 0.5 \end{cases}$$

на уровне значимости 5%.

(c) Постройте 99%-ый доверительный интервал для p .

7. Рассмотрим две выборки случайных величин X_1, \dots, X_{20} , где $X_i \sim \mathcal{N}(\mu_X, 1)$ и Y_1, \dots, Y_{20} , где $Y_i \sim \mathcal{N}(\mu_Y, 2)$. Будем предполагать, что случайные величины внутри выборок независимы и одинаково распределены, а выборки независимы между собой. Оказалось, что

$$\begin{aligned} \sum_{i=1}^{20} X_i &= 10, & \sum_{i=1}^{20} X_i^2 &= 350, \\ \sum_{i=1}^{20} Y_i &= 15, & \sum_{i=1}^{20} Y_i^2 &= 400, \end{aligned}$$

Проверьте гипотезу

$$\begin{cases} H_0 : \mu_X = \mu_Y, \\ H_1 : \mu_X \neq \mu_Y \end{cases}$$

на уровне значимости 5%.

8. Рассмотрим две выборки случайных величин X_1, \dots, X_{200} , где $X_i \sim \mathcal{N}(\mu_X, \sigma_X^2)$ и Y_1, \dots, Y_{200} , где $Y_i \sim \mathcal{N}(\mu_Y, \sigma_Y^2)$. Будем предполагать, что случайные величины внутри выборок независимы и одинаково

распределены, а выборки независимы между собой. Оказалось, что

$$\sum_{i=1}^{200} X_i = 10, \quad \sum_{i=1}^{200} X_i^2 = 350,$$

$$\sum_{i=1}^{200} Y_i = 15, \quad \sum_{i=1}^{200} Y_i^2 = 400,$$

Проверьте гипотезу

$$\begin{cases} H_0 : \mu_X = \mu_Y, \\ H_1 : \mu_X \neq \mu_Y \end{cases}$$

на уровне значимости 10%.

9. Рассмотрим две выборки случайных величин X_1, \dots, X_{25} , где $X_i \sim \mathcal{N}(\mu_X, \sigma_X^2)$ и Y_1, \dots, Y_{25} , где $Y_i \sim \mathcal{N}(\mu_Y, \sigma_Y^2)$. Будем предполагать, что случайные величины внутри выборок независимы и одинаково распределены, а выборки независимы между собой. Также будем предполагать, что $\sigma_X = \sigma_Y = \sigma$. Оказалось, что

$$\sum_{i=1}^{25} X_i = 10, \quad \sum_{i=1}^{25} X_i^2 = 350,$$

$$\sum_{i=1}^{25} Y_i = 15, \quad \sum_{i=1}^{25} Y_i^2 = 400,$$

Проверьте гипотезу

$$\begin{cases} H_0 : \mu_X = \mu_Y, \\ H_1 : \mu_X \neq \mu_Y \end{cases}$$

на уровне значимости 1%.

10. Рассмотрим выборку объектов из нормального распределения до и после проведения некоторого эксперимента. Выборку ДО обозначим как X , а выборку ПОСЛЕ обозначим как Y . Известно, что

$$X = [10, 15, 20, 18, 15, 20],$$

$$Y = [13, 13, 21, 22, 14, 25],$$

$$X_i \sim \mathcal{N}(\mu_X, \sigma),$$

$$Y_i \sim \mathcal{N}(\mu_Y, \sigma),$$

Проверьте гипотезу

$$\begin{cases} H_0 : \mu_X = \mu_Y, \\ H_1 : \mu_X \neq \mu_Y \end{cases}$$

на уровне значимости 10%.

11. На уровне значимости 10% проверьте гипотезу о том, существует ли зависимость между продолжением образования после окончания школы и типом местности, где выпускник окончил школу. В исследовании принимали участие по 100 школ из каждого типа местности.

	Не продолжил образование	Среднеспециальное образование	Высшее образование
Местность 1	40	40	20
Местность 2	30	50	20

12. **(сложная)** Компания «ГолденАльп» тестирует два новых вкуса шоколада: с орешками и солёной карамелью. Фокус-группа разбивают на две непересекающиеся части: N_1 человек пробуют шоколад с орешками, а N_2 — с солёной карамелью. Каждый участник пробует лишь один тип шоколада и одобряет или не одобряет опробованный вкус. Пусть X_1 — число человек, одобивших шоколад с орешками, а X_2 — одобивших шоколад с солёной карамелью. Будем предполагать, что $X_1 \sim \text{Bin}(N_1, p_1)$, $X_2 \sim \text{Bin}(N_2, p_2)$. Руководство компании «Голден Альп» хочет узнать, есть ли основание полагать, что один вкус шоколада предпочитается другому.

По результатам эксперимента оказалось, что $N_1 = N_2 = 500$, $X_1 = 400$, $X_2 = 390$. Сформулируйте гипотезу, которая позволит ответить на вопрос компании, и проверьте её на уровне значимости 5%.